

SaparGuard

веб-платформа с автоматическим сбором и анализом публичных транспортных объявлений

Проблема

Теневой и опасный рынок перевозок в Telegram

Ежедневно тысячи граждан пользуются услугами нелегальных межгородских такси из чатов, подвергая свои жизни опасности (нет техосмотра, нет страхования пассажиров, водители работают без сна).

Государство теряет миллионы на налогах, а контролирующие органы бессильны, потому что весь этот хаотичный рынок координируется вручную в тысячах закрытых и открытых Telegram-каналов.



Проблема мониторинга

Почему ручной контроль перевозок в Telegram не работает?

Главный барьер:

Ежедневно в чатах публикуются тысячи объявлений. Транспортные инспекторы физически не успевают обрабатывать этот массив вручную, упуская нелегальных перевозчиков.

1 Информационный хаос

В общих группах полезные объявления водителей полностью перемешаны со спамом, рекламой, запросами пассажиров и обычным флудом.



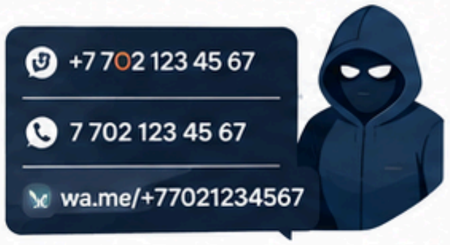
2 Данные скрыты на фото

Государственные номера автомобилей часто присутствуют только на снимках машин. Обычный текстовый поиск их просто не видит.



3 Умышленный обход поиска

Перевозчики маскируют контакты (пишут номера буквами, пробелами, ссылками WhatsApp) и часто меняют аккаунты.



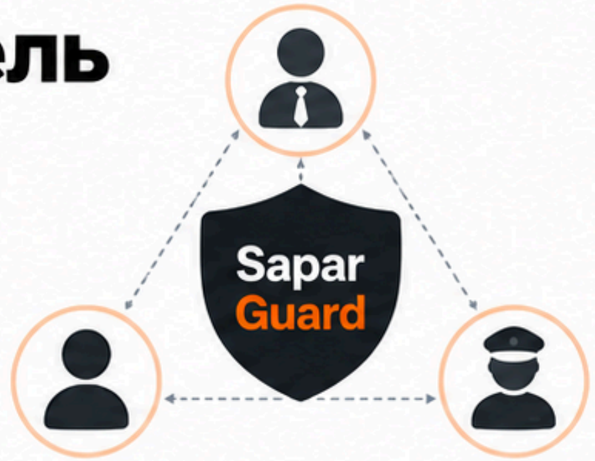
4 Трудности локализации

Объявления пишутся на казахском, русском и кыргызском языках, а названия городов часто искажаются опечатками и сленгом.



Ролевая модель SaparGuard

В системе реализовано чёткое разграничение прав доступа и три независимых пользовательских контура для совместной и безопасной работы.



1 Аналитик / Сотрудник

Главный пользователь аналитической части.

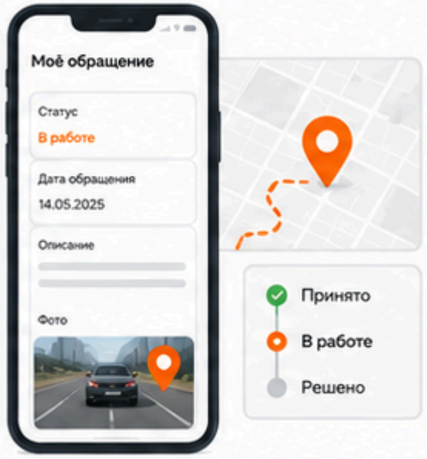
Работает с базой сообщений, профилями перевозчиков, разрешает конфликты и использует интерактивный граф связей.



2 Гражданин

Внешний пользователь.

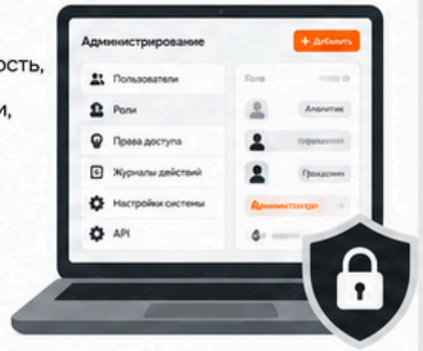
Может зарегистрироваться, быстро создать обращение о нарушении, прикрепить фото с места и отслеживать статус решения в личном кабинете.



3 Администратор

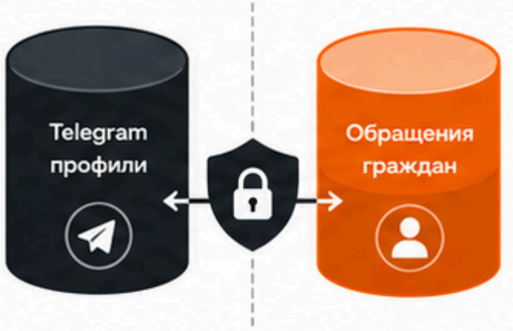
Технический пользователь.

Отвечает за общую безопасность, управляет учётными записями, настраивает роли и разграничивает доступ к внутреннему API.



4 Изоляция данных

Личные данные и обращения граждан хранятся в отдельном безопасном контуре и никогда не смешиваются с автоматически собираемыми Telegram-профилями.



5 Безопасность доступа

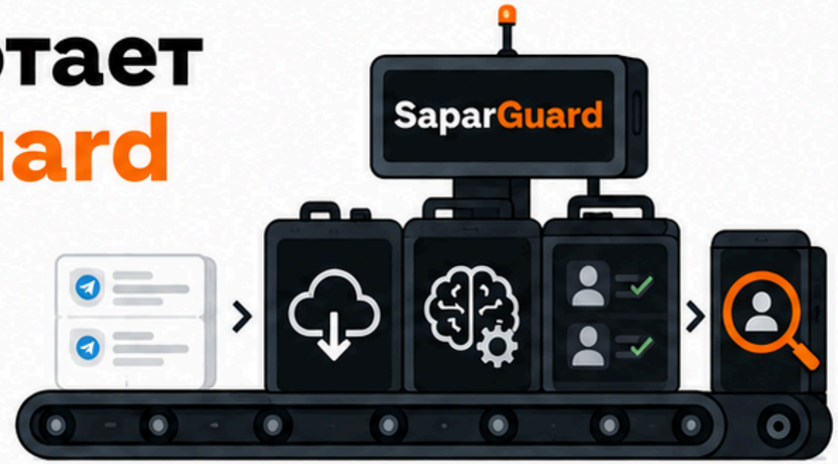
Все профили пользователей и действия защищены строгой JWT-аутентификацией на базе HttpOnly/SameSite cookie, хэшированием паролей bcrypt и политикой CSP.

JWT аутентификация + HttpOnly / SameSite cookie + Хэширование паролей bcrypt + Политика безопасности CSP

Как работает SaparGuard

Конвейер обработки данных:

автоматический сбор → NLP и Computer Vision анализ → умное объединение в профили → приоритизация для проверки человеком.



1 Сбор и предобработка

Система автоматически мониторит заданные публичные Telegram-каналы, скачивает медиафайлы, удаляет метаданные, оптимизирует изображения и передаёт их на анализ.



2 Анализ текста

Алматы – Астана
Выезд сегодня в 20:00
Тел: 8 705 123 45 67
Toyota Camry
Места есть

Телефон	+7 705 123 45 67	KZ
Марка авто	Toyota Camry	RU
Маршрут	Алматы → Астана	KG

Детерминированный NLP-модуль классифицирует сообщения, извлекает и нормализует контакты (KZ, RU, KG), распознаёт марки автомобилей и определяет направления маршрутов.

3 Распознавание номеров (ALPR)

Интегрированная модель на базе YOLO находит автомобильные номера на прикреплённых фото, а OCR-модуль считывает символы и передаёт их для сопоставления.



4 Разрешение профилей

Система связывает разрозненные объявления в единые наблюдаемые профили по телефонам, юзернеймам и госномерам, наглядно отображая связи на интерактивном графе.



5 Объяснимый скоринг (приоритет проверки)

Расчёт технического приоритета профиля от 0 до 100 баллов для определения очереди ручной проверки аналитиком.

Формируется из 6 фиксированных факторов:



Свежесть активности	до 10 баллов
Повторяемость объявлений	до 15 баллов
Независимые источники	до 20 баллов
Полнота идентификаторов	до 15 баллов
Наличие связей	до 20 баллов
Открытые конфликты	до 20 баллов

6 Контроль специалиста

Финальное решение всегда за человеком. В системе реализована удобная очередь ручной проверки для подтверждения связей, разметки и разрешения конфликтов.

☑	Профиль #12543	Связи: 8	Проверить
☐	Профиль #12544	Связи: 5	Проверить
☐	Профиль #12545	Связи: 3	Проверить



Используемые данные

1 Источники данных SaparGuard

Система работает исключительно с публичными, открытыми Telegram-группами и каналами, посвящёнными междугородним пассажирским перевозкам, которые аналитик вручную добавляет в систему.

- Алматы – Астана — 12 345 участников — публичный
- Шымкент – Алматы — 8 932 участника — публичный
- Астана – Шымкент — 6 105 участников — публичный
- Караганда – Астана — 5 231 участник — публичный

...

Источники добавляются и управляются аналитиком вручную. Система не осуществляет автоматический поиск и подключение к каналам.

2 Входящий пакет сообщения

Для каждого текстового сообщения сохраняются: уникальный ID группы и поста, дата и точное время публикации, текст, информация об авторе (если доступна) и история изменений за 7-дневное окно синхронизации.

Алматы – Астана
ID группы: -1001887654321
ID поста: 24567
08.05.2025 10:34:56 (UTC+6)

Выезд сегодня в 20:00
Алматы – Астана
Тел: +7 705 123 45 67
Места есть

1.2K 10:34

- ID группы и поста
- Дата и время
- Текст сообщения
- Информация об авторе
- История изменений (7 дней)

Хранится полная история изменений сообщения в течение 7 дней после публикации/редактирования.

3 Медиафайлы на входе

Прикрепленные к постам фотографии проходят автоматическую очистку: удаляются метаданные (EXIF), нормализуется ориентация кадра, рассчитывается хэш-сумма SHA-256 для исключения дублей и создается оптимизированный JPEG-снимок.

Исходное фото (вход)



- Удаление метаданных (EXIF)
- Нормализация ориентации
- SHA-256 хэш (исключение дублей)
- Оптимизация (JPEG)

Обработанное фото (выход)



SHA-256
a3f5c9e2d1... 7b8e4f6a9c

Дубликаты изображений не сохраняются повторно благодаря SHA-256 хэшу.

4 Выходная структура сущностей

После обработки в реляционной базе данных PostgreSQL формируются связанные таблицы: нормализованные номера телефонов, справочники городов (маршруты), марки/модели автомобилей и распознанные символы госномеров.

PostgreSQL

Телефоны

id	phone_normalized
1	+77051234567
2	+77123456789
3	+77751234567
...	...

Города (маршруты)

id	city_from	city_to
1	Алматы	Астана
2	Шымкент	Алматы
3	Астана	Караганда
...	...	...

Автомобили

id	brand	model
1	Toyota	Camry
2	Hyundai	Starex
3	Kia	Carnival
...	...	...

Госномера

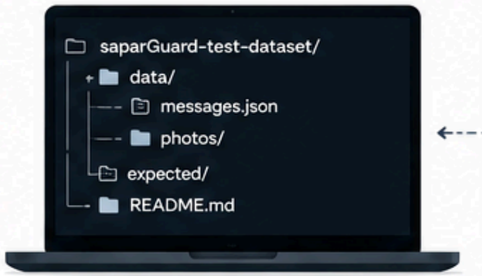
id	plate_text	plate_region
1	123ABC02	KZ
2	456DEF01	KZ
3	789GHI05	KZ
...	...	...

Связанные сущности

Все данные нормализуются и связываются между собой для дальнейшего анализа и построения профилей.

5 Тестовый датасет

В репозитории проекта присутствует небольшой синтетический набор данных, который используется исключительно как технический smoke-test для проверки работоспособности конвейера сбора и обработки.



- Синтетические сообщения
- Примеры фото
- Ожидаемый результат обработки
- Smoke-test конвейера

Датасет не содержит персональных данных и используется только для тестирования.

AI/ML-подход SaparGuard

Гибридный конвейер: правила + обученные модели для глубокой аналитики транспортной активности

1 Архитектура AI-компонентов

В основе SaparGuard лежит гибридный конвейер, сочетающий детерминированную обработку текста и обученные модели машинного зрения для глубокого анализа транспортной активности.



2 Компьютерное зрение (FastALPR)

Локализатор на базе архитектуры YOLO обнаруживает рамку номерной пластины на изображении, а специализированная OCR-модель распознаёт символы, сохраняя координаты объекта и уровень уверенности алгоритма.

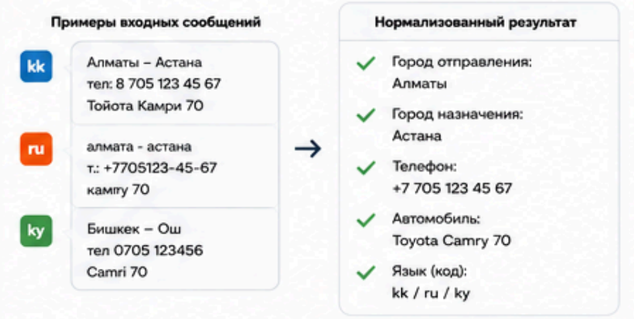


Выходные данные

Текст:	Координаты:	Уверенность:	Регион:
123 ABC 02	[x1, y1, x2, y2]	0.96	KZ

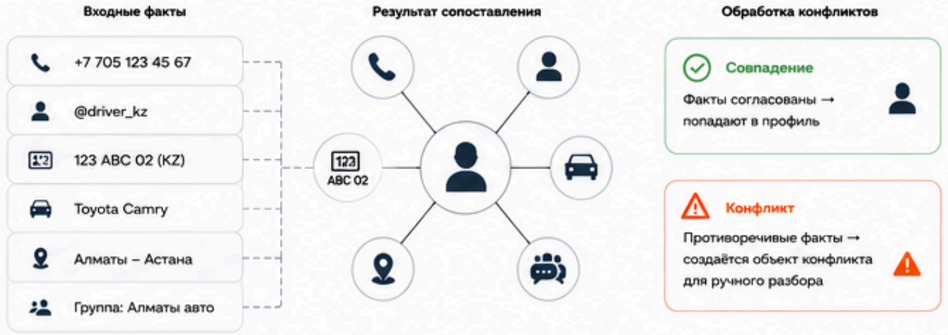
3 Извлечение и нормализация (NLP)

Модуль парсит текст по правилам трёх стран (языковые коды: kk, ru, ky). Он автоматически приводит телефоны к единому формату, исправляет опечатки в городах и распознаёт модели авто (например, «Camry 70» → Toyota Camry).



4 Алгоритм разрешения профилей

Служба сопоставления связывает разрозненные факты (телефоны, юзернеймы, госномера) в единый наблюдаемый профиль. Если алгоритм видит явные противоречия, он не скрывает их, а генерирует объект конфликта для разбора человеком.



Алгоритм не скрывает конфликты и не принимает решения вместо аналитика.

5 Интерпретируемый скоринг

Математическая модель ранжирования оценивает профили по 6 фиксированным факторам риска (максимум 100 баллов). Аналитик видит точную формулу расчёта, что исключает эффект «чёрного ящика» при определении очереди проверки.

6 факторов риска

1	Свежесть активности	до 10 баллов
2	Повторяемость объявлений	до 15 баллов
3	Независимые источники	до 20 баллов
4	Полнота идентификаторов	до 15 баллов
5	Наличие связей	до 20 баллов
6	Открытые конфликты	до 20 баллов

Формула расчёта

$$\text{Итоговый балл} = \sum_{i=1}^{6} b_i$$

где b_i — полученный балл по каждому из 6 факторов (в пределах установленного для него максимума).

(В сумме дает максимум 100 баллов).

Пример результата



Высокий приоритет проверки

Очередь: 12 из 450

Прозрачный расчёт = доверие к системе и обоснованные решения аналитика.

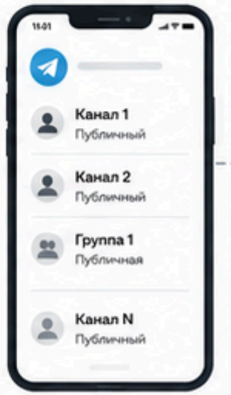
Границы применимости системы SaparGuard

SaparGuard является инструментом поддержки принятия решений, а не карательным органом. Он подсвечивает аномалии, но не выносит окончательных вердиктов.



1 Источники данных

Анализ ограничен только открытыми Telegram-источниками, которые явно добавлены в систему. Закрытые базы данных и государственные реестры не запрашиваются.



Открытые источники (добавлены)

Закрытые БД не используются

Государственные реестры не запрашиваются

2 Точность распознавания (ALPR)

Качество распознавания госномеров на фото напрямую зависит от внешних факторов: угла съёмки, освещения, разрешения кадра и степени загрязнения номерной пластины.



Исходное фото

→ KZ 123 ABC 02

Распознавание (OCR)

→

Результат

123 ABC 02

Уверенность: 0.72

72%

3 Условность профилей

Наблюдаемый профиль связывает факты из сети (телефоны, авто, юзернеймы), но не является юридически подтверждённой личностью и не доказывает право владения машиной.



Не является подтверждением личности и права владения транспортом

4 Статус скоринга

Высокий показатель приоритета в системе (от 0 до 100) — это лишь сигнал для первоочередной ручной проверки аналитиком, а не подтверждение факта правонарушения.



Высокий приоритет

Факторы скоринга (макс. 100 баллов)

Свежесть активности	до 10 баллов
Повторяемость объявлений	до 15 баллов
Независимые источники	до 20 баллов
Полнота идентификаторов	до 15 баллов
Наличие связей	до 20 баллов
Открытые конфликты	до 20 баллов

Сигнал для первоочередной проверки человеком, а не подтверждение правонарушения

5 Необходимость проверки

Все автоматические результаты работы NLP-модулей, классификатора и Computer Vision требуют обязательной финальной валидации человеком.



Планы развития SaparGuard

Ключевые направления развития системы на ближайшие этапы

1 Разметка данных (Планы)

Сбор и ручная разметка качественного датасета из 100–200 реальных сообщений на трёх языках (kk, ru, ky) для точного замера метрик качества (Precision, Recall, F1).

kk — Алматы → Астана
Ертең шығамын, орын бар.

ru — Алматы – Астана
Завтра выезд, места есть.

ky — Алматыдан Бишкекке
Эртен чыгам, орун бар.

100–200 сообщений

Precision	82%
Recall	78%
F1-score	0.80

2 Обучение NLP-моделей

Переход от текущих жестких детерминированных правил классификации текста к полноценно обученной NLP-модели для более гибкого анализа сообщений.

Текущие правила

Если есть «алматы» → город = Алматы

Если есть «астана» → город = Астана

Если есть «бишкек» → город = Бишкек

...

NLP-модель

Гибкий анализ любых формулировок

3 Расширение словарей

Масштабирование встроенных справочников: добавление редких марок и моделей авто, расширение списка населённых пунктов и внедрение устойчивой обработки опечаток и транслитерации.

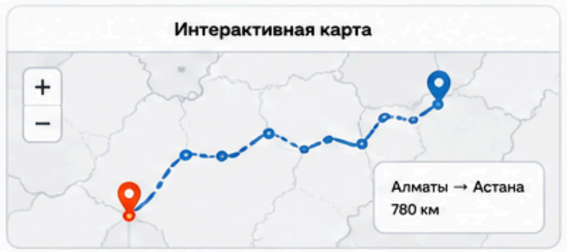
Автомобили
- Редкие марки
- Новые модели
- Варианты написания

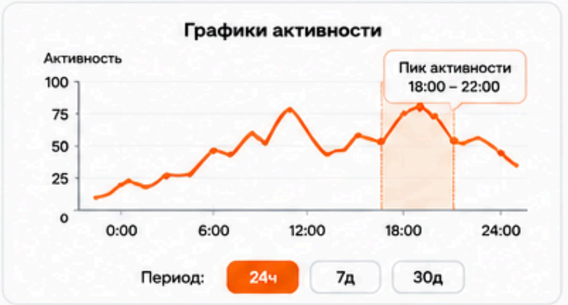
Населённые пункты
- Больше городов
- Посёлки, сёла
- Альтернативные названия

Опечатки и транслитерация
- Устойчивость к опечаткам
- Транслит, кириллица, латиница

4 Развитие функционала

Интеграция интерактивной географической карты для наглядной визуализации маршрутов и добавление временных графиков пиковой активности наблюдаемых профилей.





5 Регламенты и безопасность

Разработка чётких правил модерации системных конфликтов и формализованной политики безопасного хранения и удаления собранных данных.

Правила модерации конфликтов
Прозрачный процесс разбора и эскалации

Безопасное хранение
Шифрование, контроль доступа, аудит действий

Удаление данных
Политика сроков хранения и безопасного удаления